



UNIVERSIDAD TORCUATO DI TELLA

Trabajo Práctico

Programación Estadística Avanzada - Maestría en
Econometría

- **Profesor:** Ian Evangelos Bounos
- **Alumno:** Javier Ignacio Turdera
- **Fecha de Entrega:** 21 de Septiembre de 2026

Introducción

El valor de las viviendas está relacionado con características del distrito como el nivel de ingresos, su tamaño, ubicación y proximidad al océano. Este trabajo analiza en qué medida estas variables permiten explicar y predecir el valor mediano de las viviendas en California.

Para ello, se utiliza el dataset California Housing Prices de Kaggle. Se estima un modelo OLS como referencia y se lo compara con Ridge y LASSO, aprovechando la elevada correlación entre algunos predictores y la capacidad de LASSO para seleccionar variables.

El análisis comprende la exploración y limpieza de los datos, la estimación de los modelos y la evaluación de su desempeño predictivo fuera de muestra.

1 Datos y análisis exploratorio

Se utiliza el dataset *California Housing Prices*, que contiene información sobre 20.640 distritos de California. La variable dependiente es `median_house_value`, mientras que las variables explicativas incluyen características habitacionales, demográficas y geográficas, como ingreso, cantidad de habitaciones, población, ubicación y proximidad al océano.

En particular, `median_income` representa el ingreso mediano del distrito y constituye una medida del nivel socioeconómico. `total_rooms`, `total_bedrooms`, `population` y `households` son medidas agregadas del tamaño y la composición demográfica de cada distrito, mientras que `housing_median_age` representa la antigüedad mediana de las viviendas. Por su parte, `longitude` y `latitude` incorporan información sobre la ubicación geográfica y `ocean_proximity` clasifica los distritos según su proximidad al océano. Estas variables permiten considerar conjuntamente dimensiones económicas, habitacionales, demográficas y geográficas potencialmente asociadas al valor de las viviendas.

La única variable con valores faltantes fue `total_bedrooms`, con 207 observaciones afectadas (aproximadamente 1% de la muestra). Estas observaciones fueron eliminadas, obteniendo una muestra final de 20.433 distritos. La variable `ocean_proximity` fue tratada como categórica.

El análisis exploratorio mostró una marcada asimetría en la distribución del valor de las viviendas y una concentración de 958 observaciones en el máximo registrado, USD 500.001. Dado que no existe evidencia suficiente para considerarlas errores, estas observaciones fueron conservadas.




Figure 1: Distribución del valor mediano de las viviendas.

La relación entre `median_income` y `median_house_value` es positiva: los distritos con mayores ingresos tienden a presentar mayores valores de las viviendas. Sin embargo, la dispersión es considerable, indicando que el ingreso por sí solo no explica completamente las diferencias observadas.




Figure 2: Relación entre ingreso y valor mediano de las viviendas.

También se observan diferencias en el valor de las viviendas según `ocean_proximity`. Los distritos clasificados como INLAND presentan, en general, valores inferiores a los de las categorías NEAR BAY y NEAR OCEAN. La categoría ISLAND debe interpretarse con cautela debido a que cuenta únicamente con cinco observaciones.

Table 1: Distribución de los distritos según proximidad al océano

Categoría	Distritos	Porcentaje
<1H OCEAN	9.034	44,21%
INLAND	6.496	31,79%
ISLAND	5	0,02%
NEAR BAY	2.270	11,11%
NEAR OCEAN	2.628	12,86%
Total	20.433	100%

La matriz de correlaciones muestra una elevada asociación entre las variables relacionadas con el tamaño de los distritos. Las correlaciones entre `total_rooms`, `total_bedrooms`, `population` y `households` superan 0,85 en varias combinaciones. También se observa una correlación de -0,925 entre `longitude` y `latitude`. Por su parte, `median_income` presenta la mayor correlación lineal con la variable dependiente entre los predictores numéricos (0,688).




Figure 3: Matriz de correlaciones entre variables numéricas.

2 Metodología

A partir de los resultados exploratorios se estimaron tres modelos: OLS, Ridge y LASSO. OLS se utiliza como modelo de referencia, mientras que

Ridge y LASSO permiten abordar la elevada correlación observada entre algunos predictores.

El modelo OLS se especifica como

$$Y_i = \beta_0 + X_i\beta + \varepsilon_i, \quad (1)$$

donde Y_i representa el valor mediano de las viviendas y X_i contiene las características observadas del distrito.

Ridge incorpora una penalización sobre el tamaño de los coeficientes, mientras que LASSO utiliza una penalización que además puede llevar algunos coeficientes exactamente a cero. Esto último permite utilizar LASSO como mecanismo de selección de variables.

Para evaluar la capacidad predictiva, la muestra se dividió aleatoriamente en un conjunto de entrenamiento (80%) y uno de prueba (20%). Se utilizó una semilla fija, `set.seed(1234)`, para garantizar la reproducibilidad.

Los valores de λ de Ridge y LASSO fueron seleccionados mediante validación cruzada de diez particiones sobre el conjunto de entrenamiento. Finalmente, los tres modelos fueron evaluados sobre el conjunto de prueba mediante RMSE, MAE y R^2 .

3 Resultados

La Tabla 2 presenta el desempeño predictivo de los tres modelos sobre el conjunto de prueba.

Table 2: Desempeño predictivo fuera de muestra

Modelo	RMSE	MAE	R^2
OLS	66.965	49.172	0,6607
Ridge	66.989	49.176	0,6604
LASSO	66.977	49.174	0,6606

Los tres modelos presentan un desempeño predictivo muy similar. El RMSE se encuentra alrededor de USD 67.000 en los tres casos, mientras que el R^2 fuera de muestra se ubica en torno a 0,66. La incorporación de regularización no genera, por lo tanto, una mejora sustancial respecto del modelo OLS en esta partición de los datos.




Figure 4: RMSE de los modelos sobre el conjunto de prueba.

El análisis de LASSO aporta además información sobre la selección de variables. Con $\lambda_{\min}$, todos los predictores permanecen activos. En cambio, utilizando λ_{lse} , se eliminan `total_rooms` y `ocean_proximity` NEAR BAY. Esto no implica que estas variables no estén relacionadas con el valor de las viviendas, sino que bajo una penalización más fuerte no resultan necesarias dentro de la especificación estimada.

4 Diagnóstico y limitaciones

El gráfico de residuos del modelo OLS muestra que los errores se concentran principalmente alrededor de cero, aunque presentan una dispersión considerable. En los valores predichos más elevados se observa una concentración de residuos negativos y una estructura diagonal asociada a las observaciones cuyo valor de la vivienda alcanza el máximo registrado de USD 500.001.




Figure 5: Residuos frente a valores predichos del modelo OLS.

Una primera limitación es que la unidad de observación es el distrito, por lo que las variables habitacionales y demográficas representan agregados y no características de viviendas individuales. Además, la concentración de observaciones en USD 500.001 puede afectar tanto la estimación como la evaluación predictiva. Finalmente, los resultados describen asociaciones y capacidad predictiva, y no deben interpretarse como relaciones causales.

5 Conclusiones

El análisis muestra que las características observadas de los distritos contienen información relevante para explicar y predecir el valor mediano de las viviendas. Entre los principales resultados se destaca la relación positiva entre ingreso y valor de las viviendas y la elevada correlación entre las variables asociadas al tamaño de los distritos.

La comparación fuera de muestra muestra un desempeño muy similar entre OLS, Ridge y LASSO, con un RMSE cercano a USD 67.000 y un R^2 próximo a 0,66. En este ejercicio, la regularización no produjo una mejora predictiva sustancial respecto de OLS. Sin embargo, LASSO permitió identificar una especificación más parsimoniosa bajo la regla λ_{lse} .

Los resultados deben interpretarse teniendo en cuenta la naturaleza agregada de los datos y la existencia de un límite superior en la variable dependiente.

A Apéndice

A.1 Especificación del modelo

El modelo de referencia utilizado en el análisis es una regresión lineal por mínimos cuadrados ordinarios (OLS). Para cada distrito i , la especificación puede expresarse como:

$$Y_i = \beta_0 + X_i\beta + \varepsilon_i, \quad (2)$$

donde Y_i representa el valor mediano de las viviendas del distrito, X_i contiene las variables explicativas y ε_i representa el término de error. La variable categórica `ocean_proximity` se incorporó mediante variables indicadoras.

El modelo OLS se utiliza como punto de referencia para evaluar si la regularización permite obtener mejoras en la capacidad predictiva. La estimación se realiza inicialmente sobre el conjunto de entrenamiento y su desempeño se evalúa posteriormente sobre observaciones no utilizadas para estimar los parámetros.

A.2 División de la muestra y validación

La muestra final, luego de eliminar las observaciones con valores faltantes, contiene 20.433 distritos. Se realizó una partición aleatoria de 80% de las observaciones para entrenamiento y 20% para evaluación. Se utilizó una semilla fija (`set.seed(1234)`) para garantizar que la partición pueda reproducirse.

Los modelos Ridge y LASSO requieren seleccionar el parámetro de regularización λ . Para ello se utilizó validación cruzada de 10 particiones sobre el conjunto de entrenamiento. La elección de λ se realizó sin utilizar las observaciones del conjunto de prueba, preservando así su función como evaluación fuera de muestra.

A.3 Regularización Ridge y LASSO

La estimación Ridge modifica el criterio de mínimos cuadrados incorporando una penalización sobre el tamaño de los coeficientes:

$$\min_{\beta} \left\{ \sum_{i=1}^n (Y_i - \beta_0 - X_i'\beta)^2 + \lambda \sum_{j=1}^p \beta_j^2 \right\}. \quad (3)$$

La penalización tiende a reducir la magnitud de los coeficientes y puede resultar útil cuando existe una elevada correlación entre variables explicativas. En este ejercicio, esto resulta especialmente relevante para las variables

asociadas al tamaño de los distritos, que presentan correlaciones elevadas entre sí.

LASSO utiliza una penalización basada en el valor absoluto de los coeficientes:

$$\min_{\beta} \left\{ \sum_{i=1}^n (Y_i - \beta_0 - X_i' \beta)^2 + \lambda \sum_{j=1}^p |\beta_j| \right\}. \quad (4)$$

A diferencia de Ridge, esta penalización puede producir coeficientes exactamente iguales a cero, permitiendo obtener especificaciones más parsimoniosas y utilizar el procedimiento como mecanismo de selección de variables.

Para ambos modelos, un valor elevado de λ implica una penalización más fuerte, mientras que valores menores permiten que los coeficientes se aproximen más a los obtenidos mediante OLS.

A.4 Criterios de evaluación

La capacidad predictiva se evaluó utilizando tres métricas sobre el conjunto de prueba. El error cuadrático medio en raíz (RMSE) se define como

$$RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n (Y_i - \hat{Y}_i)^2}. \quad (5)$$

El error absoluto medio (MAE) se calcula como

$$MAE = \frac{1}{n} \sum_{i=1}^n |Y_i - \hat{Y}_i|, \quad (6)$$

mientras que el coeficiente de determinación fuera de muestra se expresa como

$$R^2 = 1 - \frac{\sum_i (Y_i - \hat{Y}_i)^2}{\sum_i (Y_i - \bar{Y})^2}. \quad (7)$$

RMSE y MAE se expresan en las mismas unidades que la variable dependiente, mientras que R^2 permite evaluar la proporción de variabilidad del valor de las viviendas explicada por las predicciones del modelo respecto de un predictor constante.

A.5 Selección de variables mediante LASSO

Además de evaluar el desempeño predictivo, LASSO permite analizar cómo cambia la especificación cuando se modifica la intensidad de la penalización. Utilizando el valor de λ que minimiza el error de validación cruzada ($\lambda_{\min}$), todos los predictores permanecen activos.

Como alternativa, se consideró λ_{se} , correspondiente a una penalización más fuerte dentro de la regla de una desviación estándar. Bajo esta especificación, los coeficientes correspondientes a `total_rooms` y `ocean_proximityNEAR` `BAY` se reducen a cero. Esto no significa que estas variables carezcan de relación con el valor de las viviendas, sino que, dada la información aportada por el resto de los predictores y la penalización utilizada, no son seleccionadas por esta especificación.

A.6 Consideraciones sobre la interpretación

Los modelos estimados tienen un objetivo principalmente predictivo. Por lo tanto, los coeficientes y las relaciones encontradas no deben interpretarse como efectos causales. En particular, la existencia de correlación entre los predictores dificulta atribuir el poder predictivo a una única variable de manera aislada.

Asimismo, las observaciones corresponden a distritos y no a viviendas individuales. En consecuencia, las variables de habitaciones, dormitorios, población e ingresos representan características agregadas del distrito. Esta característica debe tenerse en cuenta al interpretar tanto los coeficientes como las predicciones obtenidas.